

✓ Ejercicio 1:

Las top 10 fechas donde hay más tweets. Mencionar el usuario (username) que más publicaciones tiene por cada uno de esos días.

**Supuesto1:** Para cumplir con lo solicitado, se trabaja el USERNAME como id unico representante de una cuenta, pero, como regla de negocio esto es incorrecto, ya que un USERNAME en twitter puede cambiar para una misma cuenta.


Ejecucion1 optimizada para Tiempo

```
%load_ext memory_profiler

import q1_time as q1t
from memory_profiler import profile
import cProfile
import pstats

@profile
def try_stat():
    profiler=cProfile.Profile()
    profiler.enable()
    li_q1t = q1t.q1_time('./farmers-protest-tweets-2021-2-4.json')
    profiler.disable()
    stats = pstats.Stats(profiler)
    stats.print_stats(0)
    print(li_q1t)

if __name__ == '__main__':
    try_stat()
```



The memory\_profiler extension is already loaded. To reload it, use:  
%reload\_ext memory\_profiler  
ERROR: Could not find file C:\Users\Usuario\AppData\Local\Temp\ipykernel\_8176\681458841.py  
Filename: c:\Users\Usuario\Downloads\challenge\_DE\src\q1\_time.py

Line #	Mem usage	Increment	Occurrences	Line Contents
16	154.0 MiB	154.0 MiB	1	@profile
17				def q1_time(file_path: str) -> List[Tuple[datetime.date, str]]:
18	154.0 MiB	0.0 MiB	1	resp = []
19	154.0 MiB	0.0 MiB	1	pd.set_option('mode.chained_assignment', None) # Levantar una excepción
20	1675.6 MiB	1521.6 MiB	1	pddf=pd.read_json(file_path, lines=True)
21	1633.5 MiB	-42.1 MiB	1	pddf=pddf[['date', 'url', 'user']]
22	1635.3 MiB	1.7 MiB	1	pddf['date_fecha'] = pddf['date'].dt.date
23				
24	1636.3 MiB	1.0 MiB	1	df_topdates = pddf.groupby('date_fecha').agg({'url': ['count']})
25	1636.3 MiB	0.0 MiB	1	df_topdates.columns = ['url_count']
26	1636.3 MiB	0.0 MiB	1	df_topdates = df_topdates.reset_index()
27	1636.3 MiB	0.0 MiB	1	df_topdates=df_topdates.sort_values(by='url_count', ascending=False)
28	1636.3 MiB	0.0 MiB	1	df_topdates = df_topdates.head(10)
29				
30				
31	1639.9 MiB	0.0 MiB	11	for indice, fila in df_topdates.iterrows():
32	1639.8 MiB	2.2 MiB	10	df_topuser_xdate = pddf[pddf['date_fecha'] == fila['date_fecha']]
33	1639.8 MiB	0.3 MiB	198744	df_topuser_xdate['identificador'] = df_topuser_xdate['user'].apply(lambda x:
34	1639.8 MiB	0.7 MiB	10	df_topuser_xdate = df_topuser_xdate.groupby('identificador').agg({'url': ['c
35	1639.8 MiB	0.0 MiB	10	df_topuser_xdate=df_topuser_xdate.reset_index()
36	1639.8 MiB	0.0 MiB	10	df_topuser_xdate.columns = ['identificador', 'url_count']
37	1639.9 MiB	0.4 MiB	10	df_topuser_xdate=df_topuser_xdate.sort_values(by='url_count', ascending=False
38	1639.9 MiB	0.0 MiB	10	df_topuser_xdate = df_topuser_xdate.head(1)
39	1639.9 MiB	0.0 MiB	10	resp.append((fila['date_fecha'],df_topuser_xdate['identificador'].values[0])
40				
41	1639.9 MiB	0.0 MiB	1	return resp

672858 function calls (671326 primitive calls) in 10.129 seconds

[(datetime.date(2021, 2, 12), 'RanbirS00614606'), (datetime.date(2021, 2, 13), 'MaanDee08215437'), (datetime.date(2021, 2, 17), 'Raa

Resultado

```
[
(datetime.date(2021, 2, 12), 'RanbirS00614606'),
(datetime.date(2021, 2, 13), 'MaanDee08215437'),
(datetime.date(2021, 2, 17), 'RaaJVinderkaur'),
(datetime.date(2021, 2, 16), 'jot_b'),
```

```
(datetime.date(2021, 2, 14), 'rebelpacifist'),
(datetime.date(2021, 2, 18), 'neetuanjle_nitu'),
(datetime.date(2021, 2, 15), 'jot_b'),
(datetime.date(2021, 2, 20), 'MangaJ23056160'),
(datetime.date(2021, 2, 23), 'Surrypuria'),
(datetime.date(2021, 2, 19), 'Preetm91')
]
```

(t+) se aprecia que el consumo de memoria en cada instruccion es de ~1640MiB para casi todas las instrucciones del primer y segundo bloque, el tiempo es de aproximados 10 seconds

✓ Ejecucion1 optimizada para Memoria

```
%load_ext memory_profiler
```

```
import q1_memory as q1m
from memory_profiler import profile
import cProfile
import pstats

@profile
def try_stat():
    profiler=cProfile.Profile()
    profiler.enable()
    li_q1m = q1m.q1_memory('./farmers-protest-tweets-2021-2-4.json')
    profiler.disable()
    stats = pstats.Stats(profiler)
    stats.print_stats(0)
    print(li_q1m)
```

```
if __name__ == '__main__':
    try_stat()
```

The memory\_profiler extension is already loaded. To reload it, use:  
%reload\_ext memory\_profiler  
ERROR: Could not find file C:\Users\Usuario\AppData\Local\Temp\ipykernel\_8176\4294011426.py  
Filename: c:\Users\Usuario\Downloads\challenge\_DE\src\q1\_memory.py

Line #	Mem usage	Increment	Occurrences	Line Contents
17	157.4 MiB	157.4 MiB	1	@profile
18				def q1_memory(file_path: str) -> List[Tuple[datetime.date, str]]:
19	157.4 MiB	0.0 MiB	1	resp = []
20	157.4 MiB	0.0 MiB	1	pd.set_option('mode.chained_assignment', None) # Levantar una excepci3n
21	157.4 MiB	0.0 MiB	1	with open(file_path, 'r') as f:
22	570.8 MiB	-15426.6 MiB	117410	data = [[json.loads(line)['url'], pd.to_datetime(json.loads(line)['date']),
23	438.5 MiB	-132.3 MiB	1	columns = ['url', 'date', 'identificador']
24	440.4 MiB	1.9 MiB	1	pddf = pd.DataFrame(data, columns=columnas)
25	444.1 MiB	3.7 MiB	1	pddf['date_fecha'] = pddf['date'].dt.date
26				
27	444.2 MiB	0.1 MiB	1	df_topdates = pddf.groupby('date_fecha').agg({'url': ['count']})
28	444.2 MiB	0.0 MiB	1	df_topdates.columns = ['url_count']
29	444.2 MiB	0.0 MiB	1	df_topdates = df_topdates.reset_index()
30	444.2 MiB	0.0 MiB	1	df_topdates=df_topdates.sort_values(by='url_count', ascending=False)
31	444.2 MiB	0.0 MiB	1	df_topdates = df_topdates.head(10)
32				
33	444.2 MiB	0.0 MiB	11	for indice, fila in df_topdates.iterrows():
34	444.2 MiB	-27.3 MiB	10	df_topuser_xdate = pddf[pddf['date_fecha'] == fila['date_fecha']]
35				#df_topuser_xdate['identificador'] = df_topuser_xdate['user'].apply(lambda x
36	441.2 MiB	-30.3 MiB	10	df_topuser_xdate = df_topuser_xdate.groupby('identificador').agg({'url': ['c
37	441.2 MiB	0.0 MiB	10	df_topuser_xdate=df_topuser_xdate.reset_index()
38	441.2 MiB	0.0 MiB	10	df_topuser_xdate.columns = ['identificador','url_count']
39	441.2 MiB	0.0 MiB	10	df_topuser_xdate=df_topuser_xdate.sort_values(by='url_count', ascending=False
40	441.2 MiB	0.0 MiB	10	df_topuser_xdate = df_topuser_xdate.head(1)
41	441.2 MiB	0.0 MiB	10	resp.append((fila['date_fecha'],df_topuser_xdate['identificador'].values[0]))
42				
43	441.2 MiB	-3.0 MiB	1	return resp

144211904 function calls (144093254 primitive calls) in 403.207 seconds

```
[(datetime.date(2021, 2, 12), 'RanbirS00614606'), (datetime.date(2021, 2, 13), 'MaanDee08215437'), (datetime.date(2021, 2, 17), 'Ra
```

Resultado

```
[
(datetime.date(2021, 2, 12), 'RanbirS00614606'),
```

```
(datetime.date(2021, 2, 13), 'MaanDee08215437'),
(datetime.date(2021, 2, 17), 'RaaJVinderkaur'),
(datetime.date(2021, 2, 16), 'jot_b'),
(datetime.date(2021, 2, 14), 'rebelpacifist'),
(datetime.date(2021, 2, 18), 'neetuanjle_nitu'),
(datetime.date(2021, 2, 15), 'jot_b'),
(datetime.date(2021, 2, 20), 'MangaJ23056160'),
(datetime.date(2021, 2, 23), 'Surrypuria'),
(datetime.date(2021, 2, 19), 'Preetm91')
]
```

(m+) se aprecia que el consumo de memoria en cada instruccion del primer y segundo bloque es de aproximados ~440MiB. y en consecuencia, el tiempo subio considerablemente a aproximados ~403 seconds

✓ Ejercicio 2:

Los top 10 emojis más usados con su respectivo conteo.

**Supuesto1:** No tengo una definicion clara de que es un emoji, ya que tecnicamente un emoji es un caracter unicode representado por un \u\*, por lo que bajo esa definicion se trabajo la solucion.

Ejecucion2 optimizada para Tiempo

```
%load_ext memory_profiler

import q2_time as q2t
from memory_profiler import profile
import cProfile
import pstats

@profile
def try_stat():
    profiler=cProfile.Profile()
    profiler.enable()
    li_q2t = q2t.q2_time('./farmers-protest-tweets-2021-2-4.json')
    profiler.disable()
    stats = pstats.Stats(profiler)
    stats.print_stats(0)
    print(li_q2t)

if __name__ == '__main__':
    try_stat()

The memory_profiler extension is already loaded. To reload it, use:
%reload_ext memory_profiler
ERROR: Could not find file C:\Users\Usuario\AppData\Local\Temp\ipykernel_8176\1025412768.py
Filename: c:\Users\Usuario\Downloads\challenge_DE\src\q2_time.py
```

Line #	Mem usage	Increment	Occurrences	Line Contents
17	430.2 MiB	430.2 MiB	1	@profile
18				def q2_time(file_path: str) -> List[Tuple[datetime.date, str]]:
19	430.2 MiB	0.0 MiB	1	pd.set_option('mode.chained_assignment', None) #evita warning
20				#cargo el jsonl como dataframe pandas
21	1665.7 MiB	1235.5 MiB	1	pddf=pd.read_json(file_path, lines=True)
22				#trabajo solo con una columna, la que hace referencia al body del tweet
23	1500.9 MiB	-164.8 MiB	1	pddf=pddf[['content']]
24				# selecciono solo las filas que tengan al menos un emoji
25	1502.7 MiB	1.8 MiB	1	pddf = pddf[pddf['content'].str.contains(r'[\U0001F300-\U0001F5FF\U0001F600-\U000
26				# elimino todo contenido que no sea un emoji
27	1502.8 MiB	0.1 MiB	33901	pddf['content'] = pddf['content'].apply(lambda x: ' '.join(re.findall(r'[\U0001F
28				# separo las celdas que tengan mas de un emoji en filas
29	246.7 MiB	-1256.2 MiB	1	pddf = pddf.assign(content=pddf['content'].str.split(' ').explode('content')).re
30				# selecciono las filas que no sean vacias
31	246.7 MiB	0.0 MiB	1	pddf = pddf[pddf['content'] != ' ']
32				
33				# count de emojis
34	246.7 MiB	0.1 MiB	1	df_topemoji = pddf.groupby('content').agg({'content': ['count']})
35	246.7 MiB	0.0 MiB	1	df_topemoji = df_topemoji.reset_index()
36				# rename de columnas
37	246.7 MiB	0.0 MiB	1	df_topemoji.columns = ['content','emoji_count']
38				# ordeno desc
39	246.7 MiB	0.0 MiB	1	df_topemoji=df_topemoji.sort_values(by='emoji_count', ascending=False)
40				# selecciono las top10
41	246.7 MiB	0.0 MiB	1	df_topemoji = df_topemoji.head(10)
42				# dataframe a lista de tuplas
43	246.7 MiB	0.0 MiB	1	list_topemoji = list(df_topemoji.to_records(index=False))

Resultado

```
[
('🙏', 7286),
('😓', 3072),
('', 3061),
('🚗', 2972),
('🍌', 2411),
('🌿', 2363),
('I', 2096),
('N', 2094),
('👤', 2080),
('❤️', 1779)
]
```

(t+) se aprecia que el consumo de memoria en al menos 4 instrucciones es de ~1500MiB luego bajando a ~246MiB, el tiempo es de aproximados 9.2 seconds

✓ Ejecucion2 optimizada para Memoria

```
%load_ext memory_profiler

import q2_memory as q2m
from memory_profiler import profile
import cProfile
import pstats

@profile
def try_stat():
    profiler=cProfile.Profile()
    profiler.enable()
    li_q2m = q2m.q2_memory('./farmers-protest-tweets-2021-2-4.json')
    profiler.disable()
    stats = pstats.Stats(profiler)
    stats.print_stats(0)
    print(li_q2m)

if __name__ == '__main__':
    try_stat()

The memory_profiler extension is already loaded. To reload it, use:
%reload_ext memory_profiler
ERROR: Could not find file C:\Users\Usuario\AppData\Local\Temp\ipykernel_8176\3497146961.py
Filename: c:\Users\Usuario\Downloads\challenge_DE\src\q2_memory.py
```

Line #	Mem usage	Increment	Occurrences	Line Contents
18	236.2 MiB	236.2 MiB	1	@profile
19				def q2_memory(file_path: str) -> List[Tuple[datetime.date, str]]:
20	236.2 MiB	0.0 MiB	1	with open(file_path, 'r') as f:
21	640.6 MiB	-1166168.4 MiB	117410	data = [[json.loads(line)['content']] for line in f.readlines()]
22	555.0 MiB	-85.6 MiB	1	columnas = ['content']
23	554.4 MiB	-0.6 MiB	1	pddf = pd.DataFrame(data, columns=columnas)
24				# elimino todo contenido que no sea un emoji
25	556.2 MiB	1.8 MiB	234815	pddf['content'] = pddf['content'].apply(lambda x: ' '.join(re.findall(r'[\U0001F
26				# separo las celdas que tengan mas de un emoji en filas
27	558.3 MiB	2.1 MiB	1	pddf = pddf.assign(content=pddf['content'].str.split(' ')).explode('content').re
28				# selecciono las filas que no sean vacias
29	558.3 MiB	0.0 MiB	1	pddf = pddf[pddf['content'] != ' ']
30				
31				# count de emojis
32	558.3 MiB	0.0 MiB	1	df_topemoji = pddf.groupby('content').agg({'content': ['count']})
33	558.3 MiB	0.0 MiB	1	df_topemoji = df_topemoji.reset_index()
34				# rename de columnas
35	558.3 MiB	0.0 MiB	1	df_topemoji.columns = ['content', 'emoji_count']
36				# ordeno desc
37	558.3 MiB	0.0 MiB	1	df_topemoji=df_topemoji.sort_values(by='emoji_count', ascending=False)
38				# selecciono las top10

```
39 558.3 MiB 0.0 MiB 1 df_topemoji = df_topemoji.head(10)
40 # dataframe a lista de tuplas
41 558.3 MiB 0.0 MiB 1 list_topemoji = list(df_topemoji.to_records(index=False))
42 558.3 MiB 0.0 MiB 1 return list_topemoji

2232748 function calls (2232547 primitive calls) in 11.611 seconds

[('', 100457), ('🙏', 7286), ('😭', 3072), ('', 3061), ('🇸🇪', 2972), ('🍊', 2411), ('🌱', 2363), ('I', 2096), ('N', 2094), ('🇺🇸',
[
```

Resultado

```
[
('🙏', 7286),
('😭', 3072),
('', 3061),
('🇸🇪', 2972),
('🍊', 2411),
('🌱', 2363),
('I', 2096),
('N', 2094),
('🇺🇸', 2080),
('❤️', 1779)
]
```

(m+) se aprecia que el consumo de memoria en cada instruccion es tiene como maximo 640MiB en una sola instruccion, luego bajando a 558MiB para la mayoria. el tiempo subio a aproximados ~11.6 seconds

✓ Ejercicio 3:

El top 10 histórico de usuarios (username) más influyentes en función del conteo de las menciones (@) que registra cada uno de ellos.

Supuesto1:

Ejecucion3 optimizada para Tiempo

```
%load_ext memory_profiler

import q3_time as q3t
from memory_profiler import profile
import cProfile
import pstats

@profile
def try_stat():
    profiler=cProfile.Profile()
    profiler.enable()
    li_q3t = q3t.q3_time('./farmers-protest-tweets-2021-2-4.json')
    profiler.disable()
    stats = pstats.Stats(profiler)
    stats.print_stats(0)
    print(li_q3t)

if __name__ == '__main__':
    try_stat()

The memory_profiler extension is already loaded. To reload it, use:
%reload_ext memory_profiler
ERROR: Could not find file C:\Users\Usuario\AppData\Local\Temp\ipykernel_8176\565335560.py
c:\Users\Usuario\Downloads\challenge_DE\src\q3_time.py:25: UserWarning: This pattern is interpreted as a regular expression, and has
pddf = pddf[pddf['content'].str.contains(r'(?:[@]([a-zA-Z0-9_]+|$))', regex=True)]
Filename: c:\Users\Usuario\Downloads\challenge_DE\src\q3_time.py

Line #      Mem usage      Increment  Occurrences   Line Contents
=====
17      163.7 MiB      163.7 MiB          1      @profile
18
19      163.7 MiB          0.0 MiB          1      def q3_time(file_path: str) -> List[Tuple[datetime.date, str]]:
20          pd.set_option('mode.chained_assignment', None) #evita warning
21          #carga el jsonl como dataframe pandas
22          pddf=pd.read_json(file_path, lines=True)
23          #trabajo solo con una columna, la que hace referencia al body del tweet
24          pddf=pddf[['content']]
25          # selecciono solo las filas que tengan al menos un emoji
          pddf = pddf[pddf['content'].str.contains(r'(?:[@]([a-zA-Z0-9_]+|$))', regex=True)]
```

```
26 # elimino todo contenido que no sea un emoji
27 pddf['content'] = pddf['content'].apply(lambda x: ' '.join(re.findall(r'(?![@](?=[\p{Emoji}]))', x)))
28 # separo las celdas que tengan mas de un emoji en filas
29 pddf = pddf.assign(content=pddf['content'].str.split(' ')).explode('content').reset_index()
30 # selecciono las filas que no sean vacias
31 pddf = pddf[pddf['content'] != ' ']
32
33 # count de emojis
34 df_topmention = pddf.groupby('content').agg({'content': ['count']})
35 df_topmention = df_topmention.reset_index()
36 # rename de columnas
37 df_topmention.columns = ['content', 'mention_count']
38 # ordeno desc
39 df_topmention=df_topmention.sort_values(by='mention_count', ascending=False)
40 # selecciono las top10
41 df_topmention = df_topmention.head(10)
42 # dataframe a lista de tuplas
43 list_topmention = list(df_topmention.to_records(index=False))
44 return list_topmention
```

1075448 function calls (1074848 primitive calls) in 9.591 seconds

[('narendramodi', 2261), ('Kisanektamorcha', 1836), ('RakeshTikaitBKU', 1641), ('PMOIndia', 1422), ('RahulGandhi', 1125), ('GretaThunberg', 1046), ('RaviSinghKA', 1015), ('rihanna', 972), ('UNHumanRights', 962), ('meenaharris', 925)]

Resultado

```
[
('narendramodi', 2261),
('Kisanektamorcha', 1836),
('RakeshTikaitBKU', 1641),
('PMOIndia', 1422),
('RahulGandhi', 1125),
('GretaThunberg', 1046),
('RaviSinghKA', 1015),
('rihanna', 972),
('UNHumanRights', 962),
('meenaharris', 925)
]
```

(t+) se aprecia que el consumo de memoria en al menos 4 instrucciones es de ~1900MiB luego bajando a ~660MiB, el tiempo es de aproximados 9.5 seconds

✓ Ejecucion3 optimizada para Memoria

```
%load_ext memory_profiler

import q3_memory as q3m
from memory_profiler import profile
import cProfile
import pstats

@profile
def try_stat():
    profiler=cProfile.Profile()
    profiler.enable()
    li_q3m = q3m.q3_memory('./farmers-protest-tweets-2021-2-4.json')
    profiler.disable()
    stats = pstats.Stats(profiler)
    stats.print_stats(0)
    print(li_q3m)

if __name__ == '__main__':
    try_stat()

The memory_profiler extension is already loaded. To reload it, use:
%reload_ext memory_profiler
ERROR: Could not find file C:\Users\Usuario\AppData\Local\Temp\ipykernel_8176\3965048329.py
Filename: c:\Users\Usuario\Downloads\challenge_DE\src\q3_memory.py

Line #      Mem usage      Increment      Occurrences      Line Contents
=====
18      649.5 MiB      649.5 MiB           1      @profile
19                                  def q3_memory(file_path: str) -> List[Tuple[datetime.date, str]]:
20      649.5 MiB           0.0 MiB           1          with open(file_path, 'r') as f:
```

```
21 703.9 MiB -765573.5 MiB 117410 data = [[json.loads(line)['content']] for line in f.readlines()]
22 641.8 MiB -62.1 MiB 1 columnas = ['content']
23 642.7 MiB 0.9 MiB 1 pddf = pd.DataFrame(data, columns=columnas)
24 #trabajo solo con una columna, la que hace referencia al body del tweet
25 643.6 MiB 0.9 MiB 1 pddf=pddf[['content']]
26 # elimino todo contenido que no sea un emoji
27 644.5 MiB 0.9 MiB 234815 pddf['content'] = pddf['content'].apply(lambda x: ' '.join(re.findall(r'(?![@])([;
28 # separo las celdas que tengan mas de un emoji en filas
29 645.9 MiB 1.4 MiB 1 pddf = pddf.assign(content=pddf['content'].str.split(' ')).explode('content').res
30 # selecciono las filas que no sean vacias
31 645.9 MiB 0.0 MiB 1 pddf = pddf[pddf['content'] != ' ']
32
33 # count de emojis
34 645.9 MiB 0.0 MiB 1 df_topmention = pddf.groupby('content').agg({'content': ['count']})
35 645.9 MiB 0.0 MiB 1 df_topmention = df_topmention.reset_index()
36 # rename de columnas
37 645.9 MiB 0.0 MiB 1 df_topmention.columns = ['content','mention_count']
38 # ordeno desc
39 645.9 MiB 0.0 MiB 1 df_topmention=df_topmention.sort_values(by='mention_count', ascending=False)
40 # selecciono las top10
41 645.9 MiB 0.0 MiB 1 df_topmention = df_topmention.head(10)
42 # dataframe a lista de tuplas
43 645.9 MiB 0.0 MiB 1 list_topmention = list(df_topmention.to_records(index=False))
44 645.9 MiB 0.0 MiB 1 return list_topmention
```

2233520 function calls (2233304 primitive calls) in 11.398 seconds

[(' ', 79253), ('narendramodi', 2261), ('Kisanektamorcha', 1836), ('RakeshTikaitBKU', 1641), ('PMOIndia', 1422), ('RahulGandhi', 1125), ('GretaThunberg', 1046), ('RaviSinghKA', 1015), ('rihanna', 972), ('UNHumanRights', 962), ('meenaharris', 925)]

Resultado

[('narendramodi', 2261), ('Kisanektamorcha', 1836), ('RakeshTikaitBKU', 1641), ('PMOIndia', 1422), ('RahulGandhi', 1125), ('GretaThunberg', 1046), ('RaviSinghKA', 1015), ('rihanna', 972), ('UNHumanRights', 962), ('meenaharris', 925)]

(m+) se aprecia que el consumo de memoria tiene como maximo 650MiB en una sola instruccion, luego bajando a 150MiB para la mayoría. el tiempo subio a aproximados ~11.3 seconds